Laboratorijska vježba: Paralelno programiranje

Ivan Džanija

1. lipnja 2026.

Sadržaj

1 Zadatak 3.1 **2**

2 Zadatak 3.2 **2**
2.1 OpenCL kernel (GPU) 3
2.2 Numba: Single Core, Vectorize i GUVectorize 3

3 Zadatak 3.3 **3**
3.1 Rezultati mjerenja 3

1 Zadatak 3.1

U tablici 1 prikazana su ukupna vremena izvršavanja (u ms) bez troškova inicijalizacije okruženja (*setup overhead*). Vremena su zapisana za pojedinačno pokretanje te na kraju za konačni prosjek.

Tablica 1: Usporedba ukupnog vremena izvršavanja (ms) za atomičku verziju kernela ($N = 2^{24}$)

L	**B**	**G**	**T1 (ms)**	**T2 (ms)**	**T3 (ms)**	***Prosjek* (ms)**
32	16	512	5.067	5.271	5.513	**5.284**
32	32	1024	2.562	2.642	2.719	**2.641**
32	64	2048	1.791	1.845	1.909	**1.848**
32	128	4096	1.374	1.412	1.495	**1.427**
32	256	8192	1.398	1.496	1.582	**1.492**
64	16	1024	2.549	2.797	2.864	**2.737**
64	32	2048	1.789	1.948	1.753	**1.830**
64	64	4096	1.369	1.480	1.414	**1.421**
64	128	8192	1.378	1.505	1.541	**1.475**
64	256	16384	1.298	1.441	1.434	**1.391**
128	16	2048	2.008	2.188	2.194	**2.130**
128	32	4096	1.249	1.414	1.399	**1.354**
128	64	8192	1.323	1.581	1.457	**1.454**
128	128	16384	1.261	1.333	1.415	**1.336**
128	256	32768	1.247	1.396	1.393	**1.345**
256	16	4096	1.795	1.463	1.891	**1.716**
256	32	8192	1.331	1.435	1.456	**1.407**
256	64	16384	1.276	1.503	1.482	**1.420**
256	128	32768	1.259	1.313	1.335	**1.302**
256	256	65536	1.241	1.219	1.296	**1.252**

Iz izmjerenih podataka uočava se kako se ukupna vremena izvršavanja kreću u rasponu od cca 1.25 ms do 5.5 ms. Ukupan broj dretvi $G = B \times L$ ima najznačajniji utjecaj na performanse — povećanjem G vrijeme izvršavanja se smanjuje sve do zasićenja oko $G \approx 4096$, nakon čega daljnje povećanje broja dretvi donosi zanemarivo poboljšanje zbog ograničenja propusnosti memorije i kontencije na atomičkom brojaču.

2 Zadatak 3.2

Implementiran je izračun broja π pomoću sume reda:

$$\pi \approx \frac{4}{N} \sum_{i=0}^{N-1} \frac{1}{1 + \left(\frac{i-0.5}{N}\right)^2} \tag{1}$$

uz $N = 2^{24}$ elemenata. Implementirane su tri verzije: OpenCL kernel (GPU), Numba `@vectorize` te Numba `@guvectorize` s različitim veličinama bloka. Numba implementacije se pokreću na CPU-u koristeći sve dostupne jezgre (8).

2.1 OpenCL kernel (GPU)

Tablica 2: Vremena izvršavanja OpenCL kernelske verzije ($N = 2^{24}$, $L = 256$, $B = 256$)

Izvođenje	**Kernel (ms)**	**Prijenos GPU → RAM (ms)**	**Ukupno (ms)**
1	0.045864	0.000147	**0.046011**
2	0.045865	0.000159	**0.046024**
3	0.045865	0.000161	**0.046026**
Prosjek	0.045865	0.000156	**0.046020**

2.2 Numba: Single Core, Vectorize i GUVectorize

Sva vremena izvršavanja prikazana su u tablici 3.

Tablica 3: Vremena izvršavanja Numba verzija ($N = 2^{24}$)

Verzija	**T1 (ms)**	**T2 (ms)**	**T3 (ms)**	**Prosjek (ms)**
Python (single core)	1564.43	1572.69	1555.23	**1564.12**
`@vectorize`	22.48	14.85	16.28	**17.87**
`@guvectorize` blok 1024	4.71	6.17	7.32	**6.07**
`@guvectorize` blok 2048	4.35	5.73	5.39	**5.16**
`@guvectorize` blok 4096	4.69	4.12	4.68	**4.50**

Najbrža Numba verzija (`@guvectorize`, blok 4096, prosjek ≈ 4.5 ms) usporediva je s OpenCL kernelom (≈ 0.046 ms razlika je zbog različite platforme), dok čista Python (single core) verzija zaostaje za više od dva reda veličine.

3 Zadatak 3.3

U ovome zadatku je paralelizirana simulacija dinamike fluida u 2D prostoru na mreži dimenzija 2048×2048 kroz 1000 iteracija. Paraleliziran je Jacobijev algoritam jer za trenutnu iteraciju nema ovisnosti s trenutnim izračunima, već se koriste samo izračuni prethodne iteracije.

3.1 Rezultati mjerenja

Vrijednost konačne pogreške u oba je slučaja iznosila egzaktno **0.00125516**, čime je potvrđen uvjet matematičke ispravnosti paralelne implementacije.
Ubrzanje je dano sljedećim izrazom:

$$S = \frac{T_{serial}}{T_{parallel}} = \frac{24201.63 \text{ ms}}{1104.89 \text{ ms}} \approx \mathbf{21.90} \tag{2}$$

Paralelna verzija programa ostvaruje iznimno visoko ubrzanje od **21.90 puta** u odnosu na sekvencijalnu izvedbu. Valja napomenuti da se potpuno izgubi svo značajno ubrzanje

Tablica 4: Usporedba performansi sekvencijalnog izvođenja (CPU) i paralelne verzije (GPU) za CFD (2048×2048, 1000 iteracija)

Konfiguracija	**T1 (ms)**	**T2 (ms)**	**T3 (ms)**	***Prosjek* (ms)**
Sekvencijalno	23289.60	25716.30	23599.00	**24201.63**
Paralelno	1086.72	1148.92	1079.03	**1104.89**

ako se koristi *zastavica* `-O2` jer kompilator optimizira sekvencijalnu verziju ubacivanjem *SIMD* instrukcija i trajanje izvođenja *sekvencijalne* verzije pada na cca 1.2 sekundi, što je usporedivo s paralelnom verzijom.